

PRESENTASI PROJEK

ANGGOTA KELOMPOK :

**BROIGES HASIAN HASIBUAN
AGNES TASYA PURBA
RAYENDRA ALDO PUTRA
PANDU HARIANDIKA PRATAMA**

TUJUAN PROJEK

- 1. MEMBANGUN SISTEM KLASIFIKASI OTOMATIS YANG MAMPU MEMPREDIKSI APAKAH GOL MESSI DICETAK DI KANDANG ATAU TANDANG.**
- 2. MENGANALISIS FITUR-FITUR PENTING DALAM DATA (KOMPETISI, MENIT GOL, TIPE GOL, DLL) TERHADAP VENUE GOL.**
- 3. MEMBANDINGKAN PERFORMA EMPAT ALGORITMA ML (KNN, NAIVE BAYES, DECISION TREE, RANDOM FOREST) PADA DATASET NYATA.**

```

<class 'pandas.DataFrame'>
RangeIndex: 790 entries, 0 to 789
Data columns (total 17 columns):
#   Column                Non-Null Count  Dtype  
---  -
0   competition            790 non-null   str    
1   match_stage            790 non-null   str    
2   date                   790 non-null   str    
3   venue                  790 non-null   str    
4   club                   790 non-null   str    
5   opponent               790 non-null   str    
6   match_score            790 non-null   str    
7   player_position        790 non-null   str    
8   goal_minute            790 non-null   int64  
9   score_at_goal          790 non-null   str    
10  goal_type              790 non-null   str    
11  assist_player          790 non-null   str    
12  season                 790 non-null   str    
13  goal_decade            790 non-null   str    
14  is_home_goal           790 non-null   bool   
15  goal_minute_bucket     790 non-null   str    
16  Target_Home            790 non-null   int64  
dtypes: bool(1), int64(2), str(14)

```

SUMBER DATA SETS

MESSI ALL GOALS DATASET

INPUT (FITUR)

- Competition: Jenis kompetisi pertandingan.
- Match Stage: Tahapan pertandingan (group, final, dll).
- Date: Tanggal pertandingan berlangsung.
- Venue: Lokasi atau stadion pertandingan.
- Club: Tim yang mencetak gol.
- Opponent: Tim lawan.
- Match Score: Skor akhir pertandingan.
- Player Position: Posisi pemain yang mencetak gol.
- Goal Minute: Menit terjadinya gol.
- Score at Goal: Skor saat gol terjadi.
- Goal Type: Jenis gol (open play, penalty, dll).
- Assist Player: Pemain pemberi assist.
- Season: Musim pertandingan.
- Goal Decade: Kategori waktu gol (misal 0–10, 10–20 menit).
- Goal Minute Bucket: Kelompok menit gol.

OUTPUT (TARGET)

Klasifikasi gol berdasarkan lokasi pertandingan:

- 0 = Gol tandang (away)
- 1 = Gol kandang (home)

ALGORITMA

K-NEAREST NEIGHBOR (KNN)

Metode KNN digunakan untuk mengklasifikasikan apakah suatu gol termasuk gol kandang atau tandang berdasarkan kemiripan dengan data gol sebelumnya, seperti menit gol, jenis gol, lawan, dan situasi pertandingan.

NAIVE BAYES

Metode Naive Bayes digunakan untuk memprediksi kemungkinan gol kandang atau tandang dengan menghitung probabilitas dari setiap fitur, seperti tipe gol, posisi pemain, dan kondisi pertandingan, dengan asumsi setiap fitur saling independen.

DECISION TREE

Metode Decision Tree digunakan untuk menentukan klasifikasi gol kandang atau tandang dengan membentuk aturan keputusan berbentuk pohon, misalnya berdasarkan menit gol, jenis gol, atau tim lawan, sehingga mudah dipahami alur pengambilannya.

RANDOM FOREST

Metode Random Forest digunakan untuk meningkatkan akurasi klasifikasi dengan menggabungkan banyak decision tree, sehingga hasil prediksi gol kandang atau tandang menjadi lebih stabil dan tidak mudah dipengaruhi oleh data tertentu.

K-NEAREST NEIGHBORS (KNN)

Akurasi Model KNN: 0.57

Confusion Matrix:

```
[[ 34  62]
 [ 40 101]]
```

Classification Report:

	precision	recall	f1-score	support
0	0.46	0.35	0.40	96
1	0.62	0.72	0.66	141
accuracy			0.57	237
macro avg	0.54	0.54	0.53	237
weighted avg	0.55	0.57	0.56	237

- **Performa:** Akurasi berada di angka 0.57.
- **Analisis:** * Model cenderung lebih baik dalam memprediksi gol Kandang (recall 0.72) dibandingkan gol Tandang (recall 0.35).
- **Setelah dilakukan GridSearchCV, parameter terbaik yang ditemukan adalah n_neighbors: 3, metric: manhattan, dan weights: uniform. Namun, akurasi justru sedikit turun menjadi 0.51 pada data uji setelah tuning, yang mengindikasikan adanya potensi overfitting pada data latih atau data yang terlalu tersebar (noise).**

NAIVE BAYES (GAUSSIANNB)

Akurasi Model Naive Bayes: 0.42

Confusion Matrix:

```
[[ 81  15]
 [122  19]]
```

Classification Report:

	precision	recall	f1-score	support
0	0.40	0.84	0.54	96
1	0.56	0.13	0.22	141
accuracy			0.42	237
macro avg	0.48	0.49	0.38	237
weighted avg	0.49	0.42	0.35	237

- **Performa: Akurasi paling rendah, yaitu 0.42.**
- **Analisis:**
- **Meskipun akurasinya rendah, metode ini memiliki recall yang sangat tinggi untuk kelas 0 (Tandang) sebesar 0.84. Artinya, model ini sangat sensitif dalam mendeteksi gol Tandang, tetapi sering salah menebak gol Kandang sebagai gol Tandang (banyak False Negatives untuk kelas 1).**
- **Dalam demo prediksi data baru, model ini memberikan probabilitas mutlak (1.0) untuk kategori Tandang.**

DECISION TREE

Akurasi Model Decision Tree: 0.60

Confusion Matrix:

```
[[47 49]
 [46 95]]
```

Classification Report:

	precision	recall	f1-score	support
0	0.51	0.49	0.50	96
1	0.66	0.67	0.67	141
accuracy			0.60	237
macro avg	0.58	0.58	0.58	237
weighted avg	0.60	0.60	0.60	237

- **Performa: Akurasi sebesar 0.60.**
- **Analisis:**
- **Metode ini memberikan performa yang lebih seimbang antara presisi dan recall dibandingkan dua metode sebelumnya.**
- **Nilai F1-score untuk gol Kandang mencapai 0.67, menunjukkan model ini cukup stabil dalam mengenali pola gol di kandang melalui struktur pohon keputusannya.**

RANDOM FOREST

Akurasi Model Random Forest: 0.61

Confusion Matrix:

```
[[ 31  65]
 [ 27 114]]
```

Classification Report:

	precision	recall	f1-score	support
0	0.53	0.32	0.40	96
1	0.64	0.81	0.71	141
accuracy			0.61	237
macro avg	0.59	0.57	0.56	237
weighted avg	0.60	0.61	0.59	237

- **Performa:** Akurasi tertinggi di antara semua metode, yaitu **0.61**.
- **Analisis:**
- **Metode Terbaik:** Secara keseluruhan, Random Forest adalah model yang paling optimal untuk dataset ini.
- **Memiliki recall tinggi untuk gol Kandang (0.81), yang berarti model sangat jarang melewatkan identifikasi gol Kandang.**
- **Keunggulannya terletak pada kemampuannya menangani fitur yang banyak (315 fitur hasil one-hot encoding) tanpa mudah terkena overfitting dibandingkan pohon tunggal (Decision Tree).**

KESIMPULAN ANALISIS

1. **DOMINASI RANDOM FOREST: DALAM KASUS DATASET GOL MESSI INI, ALGORITMA BERBASIS POHON (TREE-BASED) SEPERTI RANDOM FOREST DAN DECISION TREE JAUH LEBIH UNGGUL DIBANDINGKAN BERBASIS JARAK (KNN) ATAU PROBABILITAS SEDERHANA (NAIVE BAYES).**
2. **IMBALANCE ISSUE: TERLIHAT DARI CLASSIFICATION REPORT BAHWA SEMUA MODEL LEBIH MUDAH MENGENALI GOL KANDANG (KELAS 1) KARENA JUMLAH DATANYA LEBIH BANYAK (59%) DIBANDINGKAN GOL TANDANG.**
3. **EFEKTIVITAS FITUR: PENGGUNAAN ONE-HOT ENCODING MENGHASILKAN 316 KOLOM FITUR. BANYAKNYA FITUR INI SANGAT COCOK DITANGANI OLEH RANDOM FOREST, NAMUN MENYULITKAN NAIVE BAYES KARENA ASUMSI INDEPENDENSINYA MENJADI TIDAK RELEVAN.**

INGOUDE COMPANY

THANK
You!

hello@reallygreatsite.com | +123-456-7890 |
www.reallygreatsite.com

* www.reallygreatsite.com *